Infraestructura Personal de IA

Documentación técnica — 10 de octubre de 2026

1. Hardware

PC Gamer (servidor de inferencia) — LAN 192.168.68.50 / Tailscale 100.95.162.17

Componente	Detalle
CPU	AMD Ryzen 7 9800X3D
Placa base	Gigabyte Aorus Elite B650M AX
Memoria	64 GB DDR5 @ 6400 MT/s
GPU	NVIDIA RTX 5090 (32 GB GDDR7)
Almacenamiento	SSD NVMe 2 TB + 4 TB
Fuente	Aorus 1000 W ATX 3.1 80 Plus Platinum

Notebook (cliente / equipo móvil)

Componente	Detalle
Modelo	ASUS ROG Strix G16 (2025) — actualizada a 64 GB RAM + 2 TB extra
Rol	Cliente liviano: OpenCode TUI, desarrollo, acceso remoto

2. Stack de software

Capa	Herramienta	Detalle
Inferencia	Strata (Niko1221)	Qwen3.8-Flash-Next 125B MoE, IQ3_XXS. API OpenAI/Anthropic en :8080. Experts en RAM del sistema, capas compartidas en GPU. Rendimiento: 150-200 tok/s
Agente de coding	OpenCode	Configuración global en ~/.config/opencode/opencode.json
Proveedores	strata / strata-remote	strata → http://192.168.68.50:8080/v1 (en casa); strata-remote → http://100.95.162.17:8080/v1 (fuera de casa)
Red privada	Tailscale	Tailnet personal: pc-gamer + noterogstrix. Conexión directa P2P verificada desde red 5G

2.1 Ficha técnica por componente (versiones verificadas)

Componente	Rol	Versión / estado verificado	Origen
Strata	Motor de inferencia MoE en GPU de consumo	`/health → status:ok · max_context:250000 · loaded:true · api_key:false`	Open source (Niko1221)
Qwen3.8-Flash-Next 125B	Modelo de trabajo, cuantización IQ3_XXS	n_ctx 250 000 · salida 32 768 · entrada texto + imagen	Qwen · pesos en almacenamiento local
OpenCode	Agente de coding: TUI, filesystem, shell, MCP	1.18.35 · proveedor con `@ai-sdk/openai-compatible`	Open source
Tailscale	Red privada P2P cifrada (WireGuard)	1.104.1 (go1.27.1) · ACL activa · sin port forwarding	Tailnet propio, 2 equipos
WSL2 + distro kali-linux	Pentesting sin VM ni dual-boot	distro kali-linux instalada en WSL2	nmap · Nuclei · Nikto · sqlmap · Metasploit
Windows 11 Home + Node.js	Host del cliente y runtime del CLI	Windows 11 Home · node v24.20.0	noterogstrix (cliente liviano)

2.1.1 Strata — motor de inferencia

Qué hace: motor de inferencia open source (MIT) que ejecuta Qwen3.8-Flash-Next 125B en una PC de consumo: mantiene los experts del MoE en la RAM del sistema, deja en la GPU las capas compartidas y los experts más usados, y expone una API OpenAI/Anthropic compatible en `:8080`.

Virtudes en este setup:

- Hace posible el 125B IQ3_XXS sobre una RTX 5090 + 64 GB: 150-200 tok/s medidos.
- API estándar: cualquier cliente `openai-compatible` lo usa sin plugins (también `/v1/messages` de Anthropic y `/v1/responses`).
- Instalación y update simples (`START-HERE.bat`, `UPDATE.bat`) y monitor web propio en `:8080` con GPU/CPU/RAM.
- Sin nube: nada sale del equipo; `/health` y `/v1/models` dan trazabilidad del modelo cargado.

Límites propios de la herramienta:

- No valida API keys por defecto: la autenticación se resuelve por red o con `--api-key` (por eso `/health` muestra `api_key:false`).
- Por defecto atiende una petición a la vez; habilitar `parallel` cuesta velocidad.
- Arranque pesado: carga 35-55 GB en RAM y puede congelar el PC 1-3 minutos; pide 32 GB+ de RAM y unos 80 GB de disco.
- El primer mensaje de un chat se procesa completo (~1 minuto cada 30 000 tokens); los siguientes arrancan en segundos.
- Proyecto joven, de un mantenedor y con releases muy frecuentes: conviene re-verificar comportamiento tras cada update.

Documentación oficial: github.com/Niko1221/Strata — carpeta `docs/` del repo (`DETAILS.md`, `HOW_IT_WORKS.md`, `MODELS.md`, `TROUBLESHOOTING.md`).

2.1.2 Qwen3.8-Flash-Next 125B — modelo de trabajo

Qué hace: modelo de lenguaje MoE con vision encoder del Qwen Team (Alibaba): 125B parámetros totales con 6B activos por token (más 51B de n-gram embedding y 4B MTP), 48 capas y 512 experts por capa MoE; acepta texto e imagen.

Virtudes en este setup:

- 6B activos por token: calidad de un 125B con costo computacional de un modelo chico, que es justo lo que hace viable el reparto GPU + RAM de Strata.
- Contexto nativo de 262 144 tokens (extensible a 1M); acá se usa 250 000, suficiente para un proyecto de juego completo.
- Perfil fuerte en coding agéntico y multilingüe; conserva los bloques de razonamiento entre mensajes ("preserved thinking"), útil para agentes.
- Pesos abiertos con cuantizaciones listas (GGUF de Unsloth e ISTA-DASLab): se puede subir o bajar de tamaño sin cambiar el resto del stack.

Límites propios del modelo:

- IQ3_XXS es una compresión agresiva: pierde finura fuera de código (los propios documentos señalan que los tamaños chicos se degradan en tareas finas y texto CJK).
- Arquitectura nueva (preview de la base de Qwen4: QSA, n-gram embedding, Gated Residual): menos tuning público y menos integraciones maduras que un modelo consolidado.
- Licencia Qwen Community 1.0, no Apache/MIT: trae condiciones de uso para despliegues a gran escala.
- El contexto largo no es gratis: la cache KV crece con el contexto y empuja experts fuera de la VRAM.

Documentación oficial: huggingface.co/Qwen/Qwen3.8-Flash-Next · github.com/QwenLM/Qwen3.8-Flash-Next (technical report) · qwen.ai/blog

2.1.3 OpenCode — agente de coding

Qué hace: agente de coding open source (MIT) que se usa desde la terminal, el escritorio o el IDE: lee el proyecto, edita archivos, ejecuta comandos y trabaja con cualquier proveedor de modelos.

Virtudes en este setup:

- Proveedores definidos por configuración: `strata` (LAN) y `strata-remote` (tailnet) apuntan a la misma API local; se cambian con `/models` o `-m`.
- Soporte `@ai-sdk/openai-compatible`: se conecta a Strata sin SDK propietario ni plugins.
- Herramientas reales sobre el proyecto: filesystem, shell, LSP, MCP, subagentes y comandos propios, con permisos granulares por agente y por herramienta.
- No almacena código ni contexto en servidores propios: el flujo queda entre la notebook y la PC de casa.

Límites propios de la herramienta:

- La calidad del agente es la del modelo conectado: con un modelo local cuantizado hay que aceptar ese techo.
- Bash, filesystem y MCP dan mucha superficie: sin `permissions` explícitos el agente puede tocar de más.
- Los servers MCP de terceros corren con tus credenciales y sobre tu filesystem: hay que revisar su procedencia.
- Ciclo de release muy rápido (v1 y v2 conviviendo): flags y formato de configuración pueden cambiar entre versiones.

Documentación oficial: opencode.ai · opencode.ai/docs · docs/providers · docs/config · docs/permissions

2.1.4 Tailscale — red privada

Qué hace: malla VPN basada en WireGuard: cada dispositivo recibe una IP privada estable y se conecta directo con los demás (P2P), mientras un coordinador administra identidades, claves y políticas de acceso.

Virtudes en este setup:

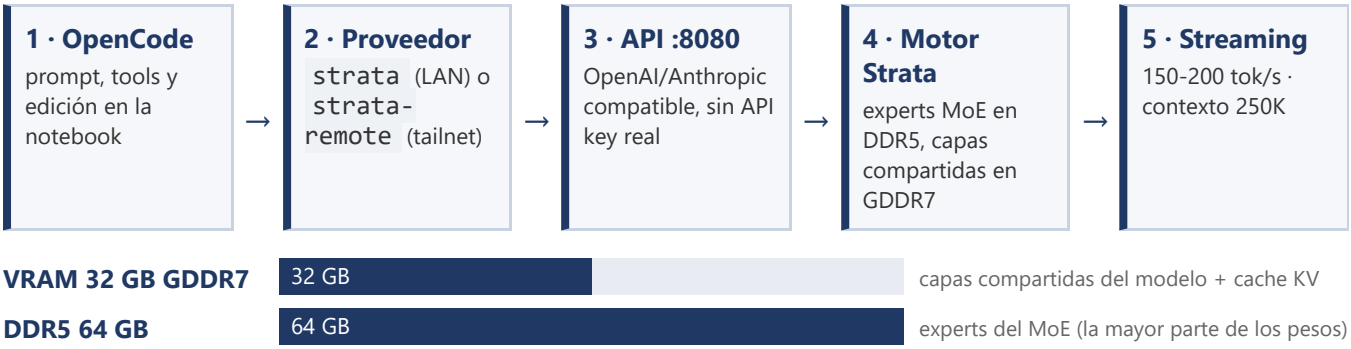
- Acceso a la PC gamer desde 5G sin abrir puertos ni tocar el router: el 8080 nunca se expone a internet.
- El coordinador es plano de control: coordina, no transporta. El tráfico cifrado va de nodo a nodo (P2P verificado, sin relay).
- NAT traversal automático, sin configurar firewalls ni puertos del router.
- ACL/grants como política de acceso (solo el propietario alcanza `pc-gamer`) y herencia del MFA de la cuenta Google.

Límites propios de la herramienta:

- El plano de control es externo: onboarding, renovación de claves y autenticación dependen del coordinador de Tailscale.
- Deja metadata en ese coordinador: nombres de dispositivos, IPs del tailnet y usuarios.
- Si el P2P falla, el tráfico puede pasar por un relay DERP (más lento).
- El plan Free tiene límites de usuarios/dispositivos y varias funciones avanzadas requieren plan de pago.
- Cliente con releases frecuentes y expiración de claves: hay que prever re-autenticaciones.

Documentación oficial: tailscale.com · tailscale.com/docs · ACLs · How Tailscale works · github.com/tailscale/tailscale

2.2 Flujo de una consulta



Lectura de la infografía: un MoE 125B cuantizado IQ3_XXS entra en una GPU de consumo porque los experts viven en la RAM del sistema y solo las capas compartidas y la cache KV ocupan la VRAM.

2.3 Comandos de verificación del stack

```
Invoke-WebRequest http://192.168.68.50:8080/health
{"status":"ok", "max_context":250000, "model":"qwen3.8-flash-next-iq3_xxs", "images":true,
"api_key":false, "loaded":true, "service":"strata"}

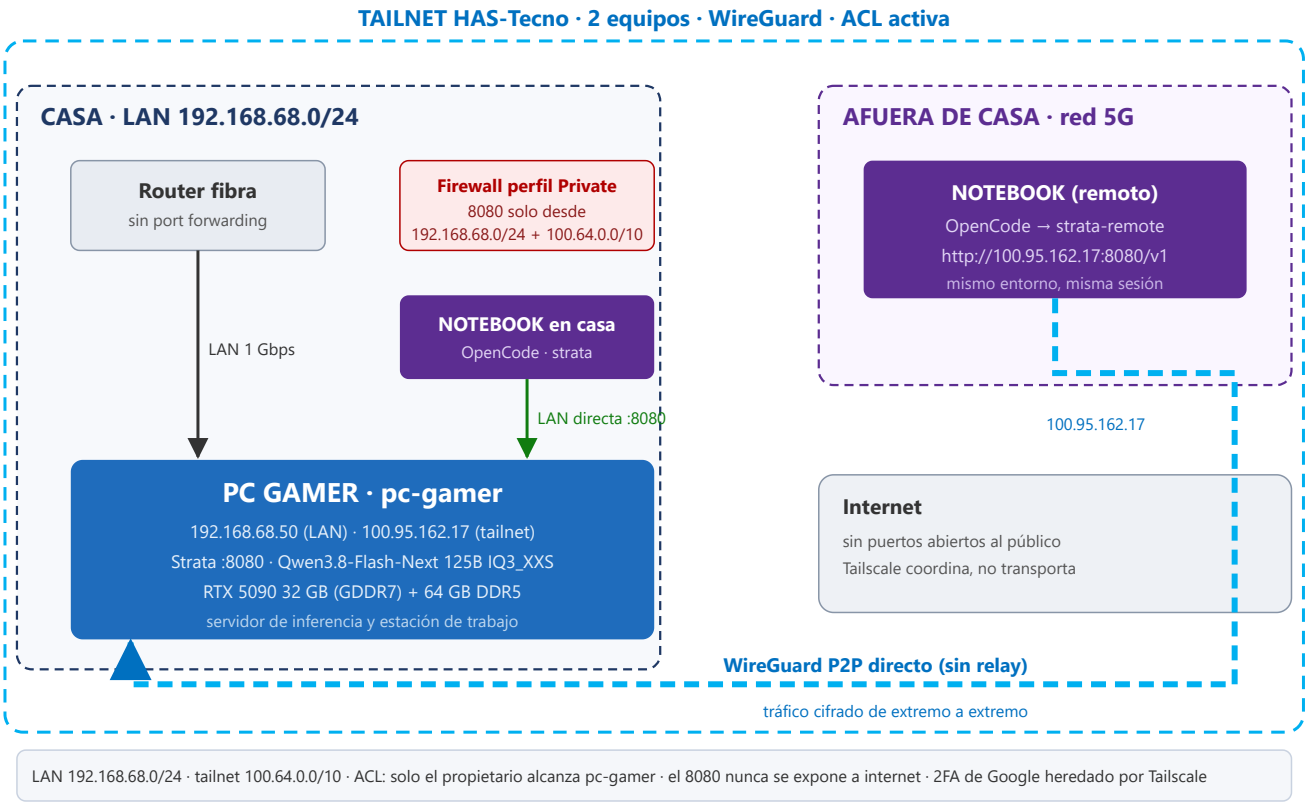
Invoke-WebRequest http://100.95.162.17:8080/v1/models
1 modelo cargado: qwen3.8-flash-next-iq3_xxs · n_ctx 250000 · entrada texto+imagen

opencode --version        1.18.35
tailscale version         1.104.1 · go1.27.1
wsl -l -v                 kali-linux · WSL2
Get-CimInstance Win32_OperatingSystem   Microsoft Windows 11 Home · noterogstrix
```

Verificado el 10/10/2026 desde `noterogstrix` usando `strata-remote` (conexión P2P por 5G). El campo `api_key:false` confirma que la seguridad del puerto 8080 se apoya en la red (firewall + ACL), no en credenciales.

2.4 Croquis de topología de red

Vista lógica del camino real de una petición: dentro de casa por LAN, y afuera por el túnel P2P de Tailscale sin abrir puertos a internet.



Cómo leerlo: los dos equipos están siempre en la misma red privada lógica (el recuadro punteado cyan). Cambia el *transporte*, no la topología: en casa el salto es LAN directa; afuera el salto atraviesa internet pero vuelve directo al nodo de casa, con la inferencia siempre en la RTX 5090.

3. Análisis de seguridad informática

Fortalezas

1. **Privacidad por diseño:** los datos nunca salen del control propio; el tráfico remoto viaja cifrado de extremo a extremo (WireGuard) normalmente P2P directo.
2. **Sin dependencia de APIs de terceros:** no hay filtrado de código a proveedores de IA comerciales ni cambios de términos de servicio.
3. **Superficie de exposición reducida:** servicio limitado a LAN + tailnet; sin puertos abiertos a internet.
4. **Autonomía ante incidentes de terceros:** caídas o brechas cloud no afectan la capacidad de trabajo local.
5. **Cuenta protegida con 2FA:** verificación en dos pasos de Google activa desde nov 2020; Tailscale hereda ese MFA automáticamente.
6. **Respaldo de proyectos:** la información de los proyectos se respalda de forma regular (práctica ya establecida).

Riesgos y mitigaciones

Cada riesgo es un item propio, con su estado y su mitigación explícita.

Riesgo A — API sin autenticación real · **Estado: CERRADO a nivel de red**

Strata no valida API keys (`api_key:false`), pero el acceso quedó acotado fuera de la aplicación:

- ✅ Firewall en la PC gamer: 8080 solo aceptado desde LAN (`192.168.68.0/24`) y Tailscale (`100.64.0.0/10`), perfil Private.
- ✅ ACL de Tailscale: solo el propietario alcanza `pc-gamer` .
- ✅ Sin port forwarding del 8080 en el router: el puerto nunca se expone a internet.

No se vuelve a tratar como riesgo abierto. Solo se reabriría si cambia la topología: port forwarding, un segundo tailnet, o un servicio escuchando fuera de esos rangos.

Riesgo B — Punto único de falla · Estado: abierto, con mitigación parcial

La PC gamer es a la vez servidor de inferencia y estación de trabajo: una falla de hardware deja sin agente de IA hasta repararla.

Mitigación aplicada: el acceso remoto ya permite seguir trabajando desde la notebook aunque el modelo esté caído, con un proveedor pago-por-uso de respaldo; respaldo regular de proyectos ya establecido; ninguna entrega atada a la disponibilidad de un solo equipo.

Riesgo C — Superficie de software y actualizaciones · Estado: abierto, en seguimiento

Strata, OpenCode y Tailscale son proyectos activos con releases frecuentes: un update puede cambiar flags, formato de configuración o comportamiento del motor. Los plugins y servers MCP que se agreguen a OpenCode amplían la superficie.

Mitigación aplicada: mantener versiones actuales (los fixes de drivers y de seguridad importan), actualizar de a un componente por vez, verificar `/health` y `opencode --version` después de cada update, y revisar los permisos de plugins/MCP en la config de OpenCode.

Riesgo D — Datos de trabajo en infraestructura personal · Estado: abierto, pendiente de definición

Usar equipos propios para tareas del empleo puede chocar con la política corporativa de clasificación de datos y confidencialidad.

Mitigación aplicada: definir la política con el área correspondiente antes de llevar datos del trabajo al entorno local. La privacidad local (el procesamiento nunca sale de hardware propio) suele ser un argumento *a favor* ante seguridad de la información.

Riesgo E — Metadata del tailnet · Estado: abierto, de exposición mínima

Los nombres de dispositivos (`pc-gamer`) y las IPs del tailnet quedan en la metadata del coordinador de Tailscale.

Mitigación aplicada: usar nombres genéricos si se quiere minimizar la exposición y extender el respaldo existente a `auth.json` y `opencode.json` (credenciales y configuración).

4. Ventajas para el uso profesional en desarrollo

- Velocidad superior a la nube: 150-200 tok/s frente a 30-120 tok/s típicos de APIs comerciales.
- Costo marginal cero para uso intensivo de agentes (ciclos de edición, tests, refactor).
- Modelo 125B MoE con contexto de 250K: trabajo sobre proyectos completos sin fragmentar el contexto.
- Continuidad geográfica: mismo entorno desde casa o desde cualquier lugar, con sesiones persistentes.

Kali Linux por WSL para auditorías

- Entorno de pentesting completo (nmap, Nuclei, Nikto, sqlmap, Metasploit) sin VM dedicada.
- Flujo con agente: escaneo → interpretación de hallazgos → redacción de informe profesional (markdown/PDF).

- Privacidad de auditorías: mapa de red y vulnerabilidades propias nunca se envían a un SaaS de escaneo.
- Repetibilidad: scripts versionados en git + informes generados por el agente.

5. Comparación frente al plan M365 corporativo

Limitante del plan corporativo	Respuesta de esta infraestructura
Integración limitada de Copilot	OpenCode: agente abierto con filesystem, shell, WSL, MCP, agentes y comandos propios
Cupo reducido de tokens	Tokens ilimitados y gratuitos con el modelo local
Datos procesados por terceros	Procesamiento íntegro en hardware propio
Modelos restringidos por plan	Elección libre de modelo, cuantización, contexto y parámetros
Dependencia de tenant/licencias	Infraestructura personal bajo control propio

Recomendación híbrida: mantener pago-por-uso mínimo (créditos de un API frontier) para razonamiento de élite ocasional; flujo diario 100% local.
